



- Message descriptor: Identifies the message and contains control information (e.g. message type, and priority) that is assigned

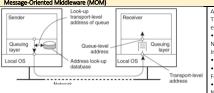
- The queue manager (not part of the message): Is responsible for accepting and delivering messages, maintains queues of all

Message besitzt Descriptor (Messaage Type, Priority,...)

Messages zu senden und zu empfangen. Sie sind über logische Kanäle übers Netzwerk miteinander verbunden

transparency, dynamic, Einfachheit, Erweiterbarkeit,

Interrupt clien Return procedure Acknowledge Reques request Time Call local procedure Call client with one-way RPC



Anzahl Verbindungen bei Peer-To-Peer bei n Teilnehmern: n * (n - 1) / 2

einige Vorteile, wie :

• geringe Kosten (die Kosten, die in ein solches Netzwerk fließen sind die für Hardware. Kahel und Instandhaltung)

• hewährte Einfachheit

 dezentral → keine zusätzliche Hardware, Felhertolerant

 Anhäufung von Ressourcen und Interoperabilität Nachteile:

· das System ist überhaupt nicht zentralisiert und damit sehr schwer zu administrieren

• es gibt kaum Sicherheit

kein einziges Glied im System ist verlässlich

O(n^2) mögliche Connections

Hub-and-Spoke Architecture with Central Message

Verbindung zwischen zwei Endknoten A und B wird nicht direk geführt, sondern über einen Zentralknoten Z geleitet Anzahl Verbindungen in Abhängigkeit der Knoten

n: n - 1 (von allen Knoten 1 Verbindung zum Hub ausser von Hub aus selber)

Weniger Verbindungen sind nötig als bei Peer

To-Peer Kleinere Netzbelastung

Single Point Of Failure

Umweg über "Router'

Hub kann Kommunikation abhören sofern diese icht verschlüsselt ist

MOM API Primitives (Platform independent)

Synch (block until queue is nonempty) /Asynch: remove first messageBrowse

Install handler to be called when message is put in queue

Non-Consuming Read

IBM MO Persistent and Non-Persistent Messages

IBM MQ assures once-only delivery of persistent messages and it assures at-most-once delivery of non-persistent

use persistant messages for critical business data (eg. receipt of payment for an order) → performance < data

Message Queuing (MSMQ) technology enables applications running at different times to communicate across heterogeneous networks and systems that may be temporarily offline. Applications send messages to gueues and read messages from queues.

can be used to implement solutions to both asynchronous and synchronous scenarios

JMS hat das Ziel, lose gekoppelte, verlässliche und asynchrone Kommunikation zwischen den Komponenten einer verteilten Anwendung zu ermöglichen. IMS bietet verschiedene Chanels (Point-to-Point, Publish-Subscribe) sowie Message Types (Text. IMS Message besteht aus Header (Infos zu Routing, Id). Properties (optional, Infos zum Filtern....). Body

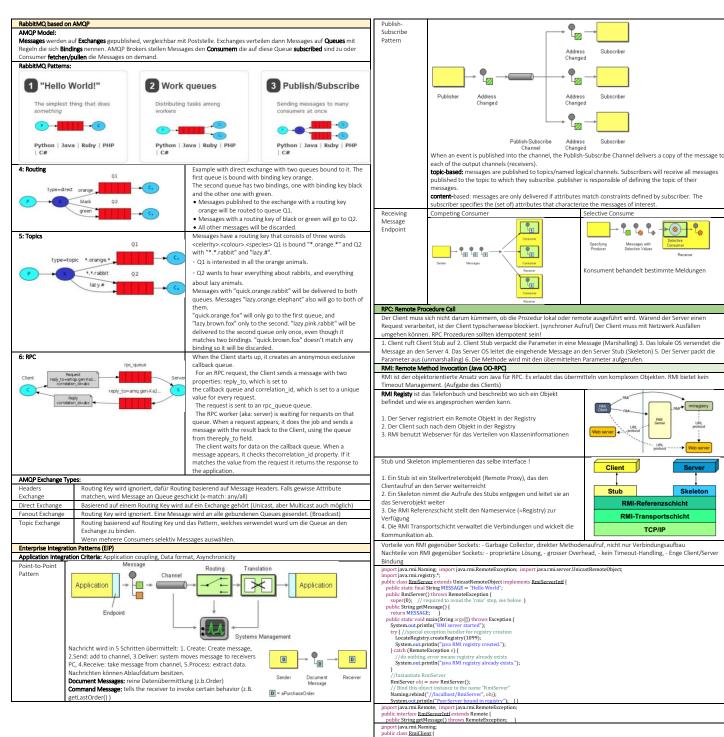
Best effort nonpersistent; Messages werden verworfen wenn eine Messaging Engine stoppt. Messages werden evtl auch verworfen wenn eine Connection unerreichbar wird oder aufgrund von beschränkten Systemressourcen unerreichbar ist.

Express nonpersistent: Messages werden verworfen wenn eine Messaging Engine stoppt. Ebenso wenn Connection

Reliable nonpersistent: Messages werden verworfen wenn eine Messaging Engine stoppt.

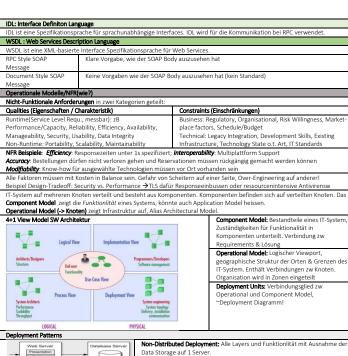
Reliable persistent: Messages werden eventuell verworfen wenn eine Messaging Engine stoppt.

Assured persistent: Messages werden nicht verworfen.



public static void main(String args∏) throws Exception {

RmiServerIntf obj = (RmiServerIntf)Naming.lookup("//localhost/RmiServer");
System.out.println(obj.getMessage()); } }







Load Balancing Cluster: Last der von Servern wo dieselbe Applikation läuft. Anfragen auf mehrere Application Jedem dieser Server wird etwa gleiche Server teilen. Auch hier Firewall zw Tiers möglich

Failover Cluster: Reliability Pattern Bei Ausfall übernimmt automatisch Failover(passiver Server mit gleichem Stand). Mit Heartbeat



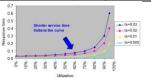
Skeleton

WSK: Wahrscheinlichkeit

Performance: Ausmass, an welchem System/Komponente seine Funktion mit Einschränkungen wie Speed, Genauigkeit, Speicherbedarf ausführen kann. Drei hauptsächliche und voneinander abhängenden Aspekte: Antwortzeiten, Durchsatz,

--> Kapazität nötig für guten Durchsatz, guter Durchsatz nötig für kurze Antwortzeiten:

Bei hoher Last steigen die Responsezeiten fast **exponentiell!** Anfragen benötigen unterschiedlich viele Resourcen, giht rechenintensive Prozesse, je mehr Anfragen desto höher WSK dass langer Prozess dahei ist, der längere Wartezeit verursacht Das wiederum erhöht WSK(mehr Anfragen in dieser Zeit) dass erneut langer Prozess dabei ist, führt zu Auslastung des Servers



Erweiterung der Infrastruktur mit Load-Balancern, etc. Scale un: Verhesserung der hestehenden Komponenten hessere Hardware (CPLL RAM, NIC, etc.) E2E Response Time: Summe der Responsezeiten aller Komponentei Schneller nicht immer genug: Real-time System verlangt auch extreme Konsistenzi

Scale out: Einsatz von mehreren Servern, Skalierung horizontal,

Scalability

Scalability is the capability to endure increasing workloads without decreasing agreed service levels if underlying resources are also increased. Types of Scalability:

Size Scalability \rightarrow Faster/More Components, Generation Scalability \rightarrow Better Components due to technological innovation, Vertical Scalability (Scale up) → increase performance of individual node, Horizonal Scalability (Scale Out) → Increase number of nodes (App sollte nicht zustandsbehaftett sein)

Load Balancer → bsp: nginx

provides site selection, workload management, session affinity, and transparent failover. intercepts data requests from clients and forwards each request to the server that is currently best able to fill the request. High availybility can be achieved by installing a backup load balancer. Load Balancer has a single virtual IP address. App Servers have own physical IP addresses. Scheduling Tactics: Round Robin Teast-recently-used, workload-based

Session affinity overrides the load-balancing algorithm by directing all requests in a session to a specific application server. (sometimes necessary for app to work correctly) It uses cookies to track session information by adding routing information to

Availability

Availability = Lack of failures which are visible to stakeholders

A system is called available if it is up and running and produces correct results, meeting other NFRs, e.g. response time

Key Availability Terms MTTR + MTTF = MTRF

Mean Time to Recover (MTTR) = von Fehler bis zu Reparatur (AVG) Mean Time to Failure (MTTF) = von Reparatur bis Fehler Mean Time between Failure (MTBF) = von Fehler bis Fehler

RTO: Recovery Time Objective) time within system must be restored (MAX)

RPO: Recovery Point Objective maximum tolerable period in which data might be lost after failure

Effect on Availability

Using components in series → Each component relies on the previous component (fällt einer aus = No service)

→ total av is lower than that of weakest link: A = A1 * A2* A3

Using components in parallel → Component redundancy through duplication (fällt einer aus = Reduzierter SErvice)

→ Total av is higher than that of the individual links A = 1 - [(1 - A1) * (1 - A2) * (1 - A3)]

24x7 availability is (almost) impossible - getting close is costly Availability numbers:

Availability %	Downtime per year	Downtime per month	Downtime per week
90% ("one nine")	36.5 days	72 hours	16.8 hours
95%	18.25 days	36 hours	8.4 hours
97%	10.96 days	21.6 hours	5.04 hours
98%	7.30 days	14.4 hours	3.36 hours
99% ("two nines")	3.65 days	7.20 hours	1.68 hours
99.5%	1.83 days	3.60 hours	50.4 minutes
99.8%	17.52 hours	86.23 minutes	20.16 minutes
99.9% ("three nines")	8.76 hours	43.8 minutes	10.1 minutes
99.95%	4.38 hours	21.56 minutes	5.04 minutes
99.99% ("four nines")	52.56 minutes	4.32 minutes	1.01 minutes
99.999% ("five nines")	5.26 minutes	25.9 seconds	6.05 seconds
99.9999% ("six nines")	31.5 seconds	2.59 seconds	0.605 seconds
99.99999% ("seven nines")	3.15 seconds	0.259 seconds	0.0605 seconds
	90% ("one nine") 90% 97% 90% 99% ("two nines") 90.9% 90.9% ("three nines") 90.99% ("fur nines") 90.99% ("four nines") 90.99% ("four nines")	90% ("Cone neer") 36 5 days 69% 18.25 days 90% 19% 1096 days 90% 19% 25 days 90% 19% 25 days 90% 19% 25 days 90.5% 18.35 days 90.5% 18.35 days 90.5% 18.35 days 90.5% 18.75 flours 90.95% 18.75 flours 90.95% 19% 25 days 90.95% 25 day	95%, "Coxe niner" 3 5 6 days 72 hours 95% 18 26 days 8 18 hours 97% 10 6 days 21 8 hours 95% 10 5 days 97% 10 6 days 21 8 hours 95% 10 5 days 97% 10 6 days 14 4 hours 95%, "T 30 days 95%, "T 30 days 95% 14 4 hours 95% 15 4 5 days 18 7 5 hours 95 5 6 hours 95 6

Branch	Cost of Downtime / Hour	
Manufacturing	28.000	
Logistics	90.000	
Retail	90.000	
Home Shopping	113.000	
Media ("pay per view")	1.100.000	
Bank (back office)	2.500.000	
Credit Card Processing	2.600.000	
Stock Brokerage	6.500.000	

Circuit Breaker Pattern: Erkenne und melde Fehler schnell (Fail Fast). Failure Threshold für Services/Funktionen werder monitored und beim Überschreiten der Threshold wird der Circuit unterbrochen -> Alerts/Events senden und darauf reagiere

Techniques to improve availybility

CFIA: Component Failure Impact Analysis → CFIA, potential SPOF: Directory Server, rarely used Component with special dependency,

Avoid single F	oints of Failure
----------------	------------------

Use redundancy (Clusters, Backups) Detect failures as fast as possible → Fail Fast!

Redundancy	

Hot Standby	Alle laufen und sind aktiv. Secondary führt Transaktionen nach
Warm Standby	Alle laufen und nur einer ist aktiv
Cold Standby	Immer nur einer aktiv

Systems Management

Systems Management umfasst: Software distribution and upgrading, version control, virus protection, user profile management, backup and recovery uym

Configuration Management: Dokumentation aller Komponenten eines Systems, Build Recreation für Maintainability,

Sind da um NFR(uA. Auditability(Nachvollziehbarkeit) zu erfüllen) Um Faktoren weiter zu überprüfen gibt es ITIL:

FCAPS: Fault, Configuration, Accounting/Administration, Performance, Security

Fault: Recognize, Isolate, Correct and Log Faults. Configuration: Monitor system configuration and other changes that take place. Accounting: Collect statistics and bill based on them Performance: Ensure Acceptable performance Security: Auth. & Authorizate

ITIL 2011 (ITIL = IT Infrastructure Library)



Sammlung vordefinierter Prozesse, Funktionen und Rollen, wie sie typischerweise in ieder IT-Infrastruktur mittlerer und großer Unternehmen vorkommen. ITIL beschreibt in fünf Kernbänden mit derzeit 37 Kernprozessen die Komponenten und Abläufe des Lebenszyklus von IT-Services.

Eine Kernanforderung an die Prozesse ist dabei die Messbarkeit

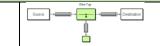
Es handelt sich dabei lediglich um Best-Practice-Vorschläge, die an die Bedürfnisse des Unternehmens angepasst werden

Systems Management Patterns to monitor and control message-/queueing-based distributed software systems

Wire Tap

Inspect Messages that travel on a point to point channel - Consume messages off the input channel and publish them to the destination and a separate inspection channel

- The Wire Tap is generic and reusable (is its own component)



Detour

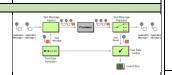
- Route a message through intermediate steps to perform validation testing or debugging

 Context based router: One state routes directly to the destination, while another takes additional steps (→detour)

 Components in the detour can inspect/modify the message In the end all the messages have the same endpoint

Test Message

- Assure the health of a message processing components Identify message processing components that are actively processing messages, but garble outgoing messages due to an internal fault



Smart Proxy

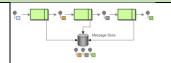
 Track/inspect messages to/from a service that sends reply messages to the Return Address specified by the Requestor intercepts messages sent to the service

- stores the return address specified by the original sender replaces the return address in the message with its own address - on the reply message, retrieves the stored return address and forwards the unmodified reply address to the original requestor

Message Store

capture information about each message in a central location - have each component send duplicates of each message to the message store

- analogy: Einschreibe-Brief



Message History

create / maintain list of all applications that the message passed through (for analyzing/debugging the message-flow) every component that processes the message adds one entry to

the message history is kept in the message header (separate

Channel Purger

- Eliminate 'left-over' messages(from previous tests reset the system into a consistent state

remove messages based on specific criteria (eg ID)



Logging	- easy to use	- no impact on performance
Requirements	- centralized	 filtering capabilites

Log content should support developers during: root cause analysis, event storms (high number of events), event correlation

Log Levels			
Frace	Debugging während Entwicklung	Debug	Debugging während Produktion (z.B. eingehende HTTP Request)
nfo	Normale Prozesse im System (User X hat Item Y bestellt, erfolgreicher HTTP Req.)	Warning	Vorgänge die evtl. näher betrachtet werden müssen (z.B. mehrmaliges falsches pw)
Error	Fehler die zum Abbruch des Vorgangs oder Runterfahren des Systems führen (z.B. Exceptions)		

CFIA: Component Failure Impact Analysis

Bei der CFIA gehts darum, vorbereitet zu sein, falls etwas schief läuft. Es ist immer anzunehmen, dass Fehler passieren. Hier geht es darum, wie damit umgegangen wird, um den Impact möglichst klein zu halten. (proaktiver Ansatz)

1. Kritische Bereiche identifizieren 2. Daten sammeln um die Wahrscheinlichkeit eines ausfalls zu verkleinern 3. Dokumentieren sodass die Zeit für die Reparatur möglichst klein ist

Workflow: Operational Model für Key Use Cases → CEIA → Risiko Logs → Technischer Fahrolan (Roadman)

Oft resultiert eine Roadmap die in 3 Phasen unterteilt ist.

Phase 1: Verbesserung welche direkt umgesetzt werden müssen (innerhalb von wenigen Wochen)

Phase 2: Wichtige Verbesserungen die innerhalb von einigen Monaten umgesetzt werden müsser

Phase 3: Verbesserungen mit tiefer Priorität die fundamentale Änderungen an der Architektur zur Folge haben.

Wichtigste Probleme, die mit CFIA gelöst werden können:

- Identification of Single Points of Failure (SPOF), where loss of a single component would impact on the non-functional character-istics of an IT service.
- · Missing or inadequately documented architecture for the IT service and operational procedures.
- Monitoring may be missing or otherwise deficient, resulting a component or service outage not being detected (eg. No. monitoring of overall IT service availability).
- Deficiencies in backup and restoration procedures that may impede recovery operations (eg. Data being stored on lots of separate tapes or backup data not being held securely).
- Processes and procedures to recover from a failure (or failover) are missing or deficient. Manual intervention means much more significant delays in recovery.
- Adequacy of backup and restore procedures
- "Key Person" dependencies where a single individual is responsible for technical support or operations for one or more components essential to the successful operation of the IT service.

CFIA Matrix: Auflisten aller Geräte und Services (Business Critical Use Cases) in einer Matrix

→Ausfüllen: Auswirkungen eines Fehlers bei diesem Gerät auf den entsprechenden Service leer = keine Auswirkungen, X = inoperativ, A=alternative available, M=alternative but manual intervention



CFIA - Risk Log

Document key findings for each CI (Node, Component, Link, etc.) to support prioritization of risks, and selection of the risks for which a solution will be proposed

 Risks that are obvious from the systems architecture prior to any
 Risks that arise from the detailed 'node' analysis. formal walkthrough · Risks that arise from previous problem records, and RCAs

recovered from an outage in a timely manner.

Lack of, or incomplete recovery procedures

o Over-complex manual tasks with no automation

o Responsibilities not defined clearly

o Recovery process is not tested

o Lack of skills

· Risks that arise from the system-level CFIA table

RCA = Root Cause Analysis

- Resilience risks: Risks which may cause a service to become Recovery risks: Risks which prevent the service from being unavailable in the first place. They are fundamental washnassas
- o Single point of failure in the IT infrastructure
- o No hot failover capability o Log files filling up
- o Bugs in code
- o Operator error Old hardware
- Security Risks: Risks which can render a service to become useless, for example, through:
- Security patch management
- Privileged users who misuse their privileges
- Denial of service attacks

Architectural Significant Use Cases → Use Case, bei dem alle Komponenten benötigt werden

Begriffe NTP

Network Time Protocol: Standard zur Synchronisierung von Uhren in Computersystemen über paketbasierte Kommunikationsnetze, NTP verwendet das verbindungslose Transportprotokoll UDP

Naming

Wieso Naming? Muss Ressource die mich interessiert finden können

Naming: Namensgebung an Entitäten

Namensauflösung: Wie eine Ressource zugegriffen werden kann mithilfe eines Namens

Name: Sequenz von Bytes/Characters, die für das Referenzieren einer Entität gebraucht werden

Entität: Anything that can be operated on. Ein Objekt, das mir eine Ressource bietet

Access Point: Spezieller Typ einer Entität der für das Zugreifen auf eine andere Enität benutzt wird Address: Name eines Access Points

Location Independent Name: Name, der unabhängig von der Adresse ist (IP, FQDN)

Identifier: Identifiziert genau eine Entität → eine Entität hat genau einen Identifier, wird nicht wiederverwendet

mDNS wie DNS, aber Name: « local»-Domain mit City + ZIP Code Recipient's Recipien Mailbox Post + Street + Number File File System File Handle (String o bytes) DNS Host Domain Name Interface Network

Jokaler Signifikanz

Flat Naming: Namen als unstrukturierte Identifier, können interne Struktur haben welche aber nicht für Namensauflösung gebraucht wird, zB Broadcasting (ARP)

Vor- und Nachteile

+ self managed (keine master nodes), einfache Implementation, location independend - broadcasting does not scale and is easy to exploit

Structured Naming: Namen sind hierarchisch strukturiert (split into layers) -> unterricht hsr.ch. Namensauflösung kann

in mehrere Schritte/Verantwortlichkeiten gesplittet werden. 7B DNS:

Am Beispiel DNS (Verwendet Kombination von beiden): Iterative Resolution: Client muss für iede Domain separate Abfrage starten. Vorteil: Entlastung der Nameservers

Nachteil: Aufwendig für Client, Hohe Latenzzeiten, weniger

Caching möglich Recursive Resolution: Client setzt eine Abfrage für gesamte

URL ab und bekommt IP zurück. Vorteil: besseres Caching möglich, einfach für Client.

Nachteil: hohe Performanceanforderungen für Nameserver Iterative Resolution macht Sinn wenn: Der Benutzer viel processing power hat und Security wichtig ist

Recursive Resolution macht Sinn wenn: Caching gefordert ist

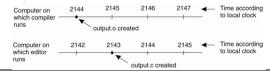
Attribute Based Naming, Ziel: Benutzer sucht Entitäten mittels Attributen, Die Entitäten sind in Form von Key-Value Paaren gespeichert (Adresse <-> Entity). Bsp: LDAP (Lightweight Directory Access Protocol (Mix Att.based/Structured))

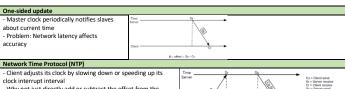
Bitcoin Naming: Flat Naming, Entity = Person, Name = Person name, Access point = Einträge in Blockchain, Address = Public Key Synchronization

Synchronising Physical Clocks

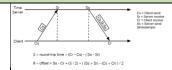
When each machine has its own clock, an event that occurred after another event may nevertheless be assigned an earlier

- Plays havoc with systems like "make





- clock interrupt interval
- Why not just directly add or subtract the offset from the current time?
- →2 Messages may have the same timestamp as a result



Synchronizing Logical Clocks

Updates on a replicated database

Solution 0:

Solution 1:

The node that wishes the update, updates its copy of the database and sends the desired update to all its peers.

node performs an update only if the update has been

The update may be lost, receiver doesn't know that he is requested to perform an update The order in which updates are performed may be

different at different nodes

All nodes must acknowledge the receipt of all updates to all It can be, that the order in which updates are performed is other nodes. Each node maintains a set of pending updates. A different at different nodes

acknowledged by all its peers.

Each node timestamps all messages it sends with the value of its physical clock. Pending updates are stored in a priority queue (priority = timestamp). A node can only perform updates in the order they are present in the queue.

Physical clocks may not be correctly synchronised. Even reasonable synchronisation, it can still be the case, that

two updates have the same timestamp

→ It is often more important that processes agree on the order of events rather than the exact point in time (physical clock) at which an event happens

Causanty			
	a≯b	- Event a happens before event b	 a → b if at least one of the following conditions are true a and b are in the same process and a occurs before b a is the event of sending a message and b is the event of receiving the same message and b is the event of receiving the same message. ∃x.a → x ∧ x → b (transitive closure)
	a b	- Event a and event b are concurrent	a b ⇔ (a → b ∧ b → a) Questions: Do concurrent events have to occur «simultaneously»(have the same timestamp)? Are all simultaneous events concurrent?

→No to both: concurrent != simultaneous, simultaneous = same physical timestamp Causal ordering doesn't solve all the problems in ordering events. There still needs to be a way to order concurrent events

Lamports Logical Clock

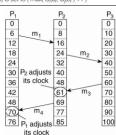
Each process P_i maintains an internal counter C_i(a) that assigns a number to all

events a occurring in process i.

- Each process P, increases C,(.) between any two successive events.
- . The current value of the counter is sent with each message.
- . If the event a is "sending m from Pi" and

the event b is "receiving m on Pi",

C_i(b) is set to (max(C_i(a), C_i(b)) +1)



- · C.(.) preserves causality: $a \rightarrow b \Rightarrow C(a) < C(b)$
- Examples?
- · Converse not true: $C(a) < C(b) \Rightarrow a \rightarrow b$

Examples? 48 < 50; event at 50 didnt happen before event at 48

Q. Is C_.(.) totally ordered?

A. Not yet. We need to introduce a fixed, but arbitrary order between event on different processes with the same counter value to make it a strict total order. Idea: use the process ID to order concurrent events.

- Each process P_i maintains an internal counter C_i(a) that assigns a number to all events a occurring in
- The (distributed) function C(.) assigns the tuple C(a) to any event a, where $C(a) = (C_1(a), i)$ where a is an event in process i
- The (overloaded) lexicographic ordering "<" is used for these tuples.
- Properties of C(.)
 - "C(.) < C(.)" is a <u>strict total order</u> (think: linked list) over events:
 - The relation C(a) < C(b) is a strict partial order over events a & b. (property of the lexicographic ordering "<")
 - Additionally comparable: (C(a) < C(b)) xor (C(a) > C(b)) xor (a = b)
 - C(.) preserves causality: a → b ⇒ C(a) < C(b)

Result: With C(.) we have a global (distributed) counter (timestamp) that is total and preserves causality!

Since Lamport's Clock defines a total order on events, it cannot capture causality exactly

- $a \rightarrow b \Leftrightarrow C(a) < C(b)$
- . In some cases it is useful to know that two events are not causally related. For
- example:
- To detect conflicts amongst distributed updates
- Scheduling and debugging concurrent computations • Vector clocks track causality between events exactly:
- $a \rightarrow b \Leftrightarrow V(a) < V(b)$

Each process Pi maintains an internal vector Vi with the following properties:

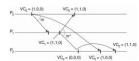
- 1. Vi[i] is the number of events that have occurred so far at Pi.
- 2. If Vi[i] = k then Pi knows that k events have occurred at Pi
- Vector clock properties are maintained with the following rules:
- 1. Increment Vi[i] with the occurrence of each new event at process Pi
- 2. Receiving a message at Pj from Pi causes Pi to additionally update each entry Vi[k] to

max(Vi[k], Vj[k]).

Example application: Enforcing causal communication

V(a) = (1, 0, 0)

Requirement: A message is delivered to the application only if all messages that causally precede it have also been delivered.



Distributed Hashtables (DHT) werden oft als redundanter / ausfallssicherer Datenspeicher eingesetzt

Chord ist eine Consistent Hashing implementierung für P2P Datenspeicherung → Ermöglicht die Zuordnung von Keys zu Nodes, ohne grosse Änderungen bei neuen Nodes.

Hash im Bereich von 0 bis 2^m-1 , mit m meistens 128 oder 160. Die Hashes werden in einem Ring angeordnet.

Hostadresse n = hash (IP)

Nachfolger n. successor ist jedem Node für seinen Nachfolger bekannt (n. successor = first node clockwise from n in the ring). Jeder Node ist für den Adressbereich bis zu seinem Vorgänger zuständig.

Die verteilte Funktion succ(_) ist dafür da, den für einen Bereich zuständigen Node zu finden

n.successor = succ(n + 1)

n.predecessor = first node counter-clockwise from n in the ring

Schlüssel: alle Objekt-Ids der Datensätze, für die ein Knoten zuständig ist

Finger Table: Ist eine «Shortcut» Tabelle, ähnlich Binary Search. Jeder Node n hat eine Finger Table mit Index $i \in \{1, ..., m\}$ Die Tablle wird mit $n. finger[i] = succ(n + 2^{i-1})$ befüllt.

Stabilisierung: Aktualisierung der Informationen im Node über das Netzwerk

Der direkte Nachfolger eines Nodes wird regelmässig Überprüft: (es gilt immer: n < x ≤ n.successor)

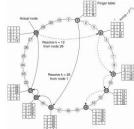
x += (n.successor).predecessor;

if (n < x < n.successor) { n.successor := x }

- Der direkte Nachfolger wird regelmässige über die Existenz informiert. Beim erhalt der Nachricht von p macht Node n: if (p.predecessor is undefined OR n.predecessor < p < n) { n.predecessor := p }
- Einträge der Finger Table werden auf einem Node n in regelmässigen Abständen zufällig aktualisiert:

i := random integer >1 and ≤m

- $finger[i] = n.successor.lookup(n + 2^{i-1}, n)$ n.lookup(k,a): Zuständigen Node für Hash/Key k von Node n aus gesehen finden und Ergebnis an Node a senden:
- 1. Falls $n.predecessor < k \le n$ ist der Node n zuständig.
- 2. Falls der Nachfolger von n Zuständig ist n < k ≤ n.successor, die Suchanfrage an diesen Node weiterleiten: n.successor.lookup(k,a)
- 3. Andernfalls wird die Anfrage an den nächsten Vorgänger q von k aus der Finger Table angefragt ($q \le k$): q.lookup(k,a) Die Effizienz eines Lookups bei korrekter Finger Table ist $O(\log N)$. (Ohne Fingertable $\rightarrow O(N)$).



Join eines Nodes na

- 1. Bestimmen der Hostadresse n = hash(IP)
- 2. Bestimmen des Nachfolgers n.successor := succ(n+1) und des Vorgängers n.predecessor := succ(n-1)
- 3. Stabilisierung
 - a. Informieren des Nachfolgers s → s.predecessor = n
 - b. Vorgänger p fragt bei s periodisch nach, ob ein neuer Node da ist, und aktualisiert seinen p.successor = n
 - c. p informiert n, dass er sein Vorgänger ist → n.predecessor = p
- 4. Stabilisierung der Finger Tables

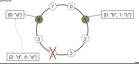


Leave eines Nodes n geplant:

- 1. Alle Ressourcen werden an n. successor übergeben
- 2. n.predecessor (=p) wird darauf hingewiesen, seinen p.successor anzupassen.
- 3. n.successor (=s) wird darauf hingewiesen, seinen s.predecessor anzupassen. Example: Node 4 leaves

V(a) < V(f)

V(a) ≮ V(b) V(c) ≮ V(f)

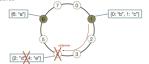


Leave eines Nodes n ungeplant:

- 1. Vorgänger p wechselt seinen Nachfolger zu s → p.successor = s
- Vorgänger p informiert s über die änderung → s.predecessor = p
- 3. Stabilisierung der Finger Tables

Ungeplante Leaves führen zu Datenverlust, wenn keine Redundanz gespeichert wird.

Example: Node 4 leaves



Bitcoin

Transaktion: Betrag, AbsenderPubKey, EmpfängerPubKey, Signatur mit PrivKey → an die Keys sind keine Namen gebunden

Blockchain: Transaktionen werden in Blöcke und danach in eine Kette eingereit. Der nachfolgende Block beinhaltet den Hash des vorherigen Blocks.

Eine totale Ordnung wird mit dem Konsensus-Protokoll erreicht.

A block B contains

- RH(B') for another block B',
 - a list of transactions, and an arbitrary number

"nonce". Block B is valid if the first d = 5 digits of thehash of B are all zero.

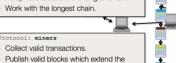


tocol: participate

Relay valid transactions.

longest chain.

- Relay valid blocks in the longest chain.



Proof of Work: Damit das erstellen eines Blocks nicht zu einfach ist, muss der Hash jedes Blocks mit einer Anzahl Nullen beginnen. Dies kann erreicht werden, indem die Nonce eines Blockes geändert wird. Ein Miner probiert jeweils so viele Nonces durch, bis er so einen Hash erreicht hat. Danach wird der valide Block im Bitcoin-Netzwerk verteilt und dessen Hash in den nächsten Block einbezogen. (Die Anzahl Nullen wählt Bitcoin so, dass im Schnitt etwa 10 Min. daran gerechnet werden muss.) Als Belohnung erhält ein Miner, welcher diesen Hash findet, eine optionale Transaction-Fee sowie «Initial Reward» von 25BTC. Transaction-Fees sind Transaktionsbeträge ohne expliziten Empfänger.

Um Double Spending zu verhindern, braucht es Konsensus-Protokoll. Bitcoin nimmt jeweils den längsten gültigen Baum als wahr an. Da es bei jeder Blockchain-Verkettung schwieriger wird, die vergangenen Transaktionen zu fälschen (da ein längerer

Baum berechnet werden müsste), reichen ca. 7 Blöcke, damit eine Transaktion sicher durchgelaufen ist. Monitoring

- Hardware failure

- Network cuts - Traffic spikes/shifts
- Cascading overload
- Hotspotting - Software bugs
- Avoid single points of failures - Load balancing

Redundancy & Redundancy

- Throttling & rate limiting - Backups

SIR RTR RTCP Layer Layer I moor 3 Network Inv4 IPv6 Laver 1 Physical Link Coax, RF link, et